

گزارش کامل فایل‌های CSV خروجی پروژه

بخش اول: فایل‌های داده (Data Files)

۱. فایل iran_city_classification.csv

(داده‌های دسته‌بندی شهرها) CSV: نوع فایل

هدف: این فایل شامل دسته‌بندی شهرهای ایران به دو گروه کلان‌شهر و شهر کوچک است.

ساختار فایل:

ستون	توضیح
نام شهر	نام شهر به انگلیسی
دسته‌بندی	کلان‌شهر / شهر کوچک

تعداد رکوردها: ۲۴۰ شهر

نمونه داده:

نام شهر	دسته‌بندی
karaj	کلان‌شهر
tehran	کلان‌شهر
mashhad	کلان‌شهر
shiraz	کلان‌شهر
isfahan	کلان‌شهر
tabriz	کلان‌شهر
qom	کلان‌شهر
ahvaz	کلان‌شهر
kermanshah	کلان‌شهر

شهر کوچک	سایر شهرها
----------	------------

کاربرد در پروژه: این فایل برای تحلیل توزیع آگهی‌ها بر اساس دسته‌بندی شهرها استفاده شده است.

۲. فایل cat2_distribution.csv

(نتایج تحلیل دسته‌بندی سطح ۲) CSV: نوع فایل

هدف: نمایش توزیع آگهی‌ها بر اساس دسته‌بندی سطح ۲ (cat2_slug)

ساختار فایل:

توضیح	ستون
نام دسته‌بندی سطح ۲	cat2_slug
تعداد آگهی‌ها	count
درصد از کل آگهی‌ها	percentage

داده‌ها:

cat2_slug	count	percentage
residential-sell	۵۵۸,۷۰۸	۵۵.۸۷٪
residential-rent	۲۷۶,۵۵۸	۲۷.۶۶٪
commercial-rent	۷۶,۵۶۷	۷.۶۶٪
commercial-sell	۳۸,۸۶۱	۳.۸۹٪
temporary-rent	۲۹,۹۰۳	۲.۹۹٪
real-estate-services	۱۹,۴۰۳	۱.۹۴٪

نکته کلیدی: بیش از ۸۳٪ آگهی‌ها مربوط به بخش مسکونی (فروش و اجاره) هستند.

۳. فایل cat3_distribution.csv

(نتایج تحلیل دسته‌بندی سطح ۳) CSV: نوع فایل

هدف: نمایش توزیع آگهی‌ها بر اساس دسته‌بندی سطح ۳ (cat3_slug)

ساختار فایل:

ستون	توضیح
cat3_slug	نام دسته‌بندی سطح ۳
count	تعداد آگهی‌ها
percentage	درصد از کل آگهی‌ها

داده‌های برتر:

cat3_slug	count	percentage
apartment-sell	۳۰۳,۳۸۵	۳۰.۳۴٪
apartment-rent	۲۱۱,۸۸۰	۲۱.۱۹٪
plot-old	۱۳۳,۵۷۰	۱۳.۳۶٪
house-villa-sell	۱۲۱,۷۵۳	۱۲.۱۸٪
house-villa-rent	۶۴,۶۷۸	۶.۴۷٪

نکته کلیدی: آپارتمان‌ها (فروش و اجاره) بیش از ۵۱٪ از کل آگهی‌ها را تشکیل می‌دهند.

۴. فایل city_category_distribution.csv

(نتایج تحلیل دسته‌بندی شهرها) CSV: نوع فایل

هدف: نمایش توزیع آگهی‌ها بر اساس دسته‌بندی شهرها

ساختار فایل:

ستون	توضیح
دسته‌بندی	کلان‌شهر / شهر کوچک
count	تعداد آگهی‌ها

percentage	درصد از کل آگهی‌ها
------------	--------------------

داده‌ها:

دسته‌بندی	count	percentage
شهر کوچک	۴۹۸,۴۷۸	۵۱.۷۵٪
کلان‌شهر	۴۶۴,۷۹۹	۴۸.۲۵٪

نکته کلیدی: توزیع تقریباً متوازن بین کلان‌شهرها و شهرهای کوچک.

بخش دوم: فایل‌های مدل‌سازی (Model Files)

فایل `model_results_q2.csv`

(نتایج ارزیابی مدل‌ها) CSV: نوع فایل

هدف: مقایسه عملکرد ۷ مدل یادگیری ماشین

ساختار فایل:

ستون	توضیح
model	نام مدل
train_r2	R^2 روی داده‌های آموزش
val_r2	R^2 روی داده‌های اعتبارسنجی
test_r2	R^2 روی داده‌های تست
train_mae	MAE روی داده‌های آموزش

val_mae	MAE روی داده‌های اعتبارسنجی
test_mae	MAE روی داده‌های تست
train_mse	MSE روی داده‌های آموزش
val_mse	MSE روی داده‌های اعتبارسنجی
test_mse	MSE روی داده‌های تست

نتایج:

مدل	val_r2	test_r2	test_mae (تومان)
Random Forest	۰.۹۹۸۵	۰.۹۹۸۴	۳۶,۳۳۴,۳۳۳
Gradient Boosting	۰.۹۹۶۲	۰.۹۹۵۵	۶۱,۹۰۳,۳۴۳
LightGBM	۰.۹۹۵۶	۰.۹۹۵۰	۶۵,۳۵۹,۳۵۹
XGBoost	۰.۹۹۵۷	۰.۹۹۴۹	۶۶,۸۰۸,۶۶۳
Lasso Regression	-۳.۷۵۶	-۴.۸۵۱	۱,۲۶۱,۲۱۵,۹۵۷

نکته کلیدی: مدل Random Forest با $R^2=0.9984$ بهترین عملکرد را دارد.

۵. فایل **best_model_q2.pkl**

(مدل ذخیره شده) Pickle: نوع فایل

هدف: ذخیره بهترین مدل (Random Forest) برای استفاده مجدد

توضیح: این فایل مدل Random Forest آموزش‌دیده را به صورت سریالایز شده ذخیره می‌کند. برای بارگذاری مجدد:

```
import joblib
```

```
model = joblib.load('best_model_q2.pkl')
```

۶. فایل **scaler_q2.pkl**

(اسکیلر ذخیره شده) Pickle: نوع فایل

هدف: ذخیره اسکالر (StandardScaler) برای استفاده مجدد

توضیح: این فایل اسکالر آموزش دیده را ذخیره می کند تا بتوان داده های جدید را با همان پارامترهای قبلی مقیاس سازی کرد:

```
import joblib

scaler = joblib.load('scaler_q2.pkl')

X_new_scaled = scaler.transform(X_new)
```

بخش سوم: فایل های تحلیل روند قیمتی (Price Trend)

۷. فایل price_trend_analysis.csv

(داده های سری زمانی قیمت) CSV: نوع فایل

هدف: ذخیره داده های قیمت ماهانه برای تحلیل روند

ساختار فایل:

توضیح	ستون
نام شهر	city
ماه (تاریخ)	month
میانگین قیمت	avg_price
تعداد آگهی ها	count
میانه قیمت	median_price

نمونه داده:

city	month	avg_price	count
tehran	۲۰۲۴-۰۵-۳۱	۱.۰	۲,۶۲۵
karaj	۲۰۲۴-۰۸-۳۱	۱.۰	۸۶۹
mashhad	۲۰۲۴-۰۹-۳۰	۱.۰	۷۰۴

نکته کلیدی: این داده‌ها برای تحلیل روند قیمتی و پیش‌بینی با Prophet استفاده شده‌اند.

بخش چهارم: خلاصه فایل‌های CSV

تعداد رکورد	کاربرد	نام فایل
۲۴۰	دسته‌بندی شهرها	iran_city_classification.csv
۶	توزیع دسته‌بندی سطح ۲	cat2_distribution.csv
۱۶	توزیع دسته‌بندی سطح ۳	cat3_distribution.csv
۲	توزیع دسته‌بندی شهر	city_category_distribution.csv
۷	نتایج مدل‌ها	model_results_q2.csv
+۶۰	داده‌های سری زمانی قیمت	price_trend_analysis.csv

جمع‌بندی نهایی

۱. فایل‌های داده: اطلاعات کامل دسته‌بندی آگهی‌ها و شهرها را ارائه می‌دهند.
۲. فایل‌های مدل: نتایج نشان می‌دهد Random Forest بهترین مدل با $R^2=0.9984$ است.
۳. فایل‌های سری زمانی: داده‌های قیمت ماهانه برای تحلیل روند و پیش‌بینی آماده شده‌اند.
۴. فایل‌های ذخیره شده: مدل و اسکریپت برای استفاده مجدد در آینده ذخیره شده‌اند.

تاریخ: جولای ۲۰۲۶

نویسنده: الناز رادمند