

خلاصه پروژه

این پروژه شامل سه بخش اصلی است که بر روی داده‌های آگهی‌های املاک دیوار انجام شده است:

۱. تحلیل آماری (Statistics Analysis)

۲. پیش‌بینی قیمت با یادگیری ماشین (ML Price Prediction)

۳. مسائل پیشرفته (Advanced ML Tasks)

بخش اول: تحلیل آماری داده‌های دیوار

معرفی

در این بخش، داده‌های آگهی‌های املاک دیوار مورد تحلیل آماری قرار گرفته‌اند. هدف اصلی، شناسایی توزیع آگهی‌ها در سطوح مختلف دسته‌بندی و تحلیل جغرافیایی آگهی‌ها است.

مراحل انجام شده

۱. بارگذاری داده‌ها

- فایل اصلی Divar.csv: با بیش از ۱ میلیون رکورد و ۶۱ ویژگی
- فایل کمکی iran_city_classification.csv: برای دسته‌بندی شهرها

encoding بارگذاری با پشتیبانی از چندین #

try:

```
df = pd.read_csv('Divar.csv', encoding='utf-8')
```

except UnicodeDecodeError:

```
df = pd.read_csv('Divar.csv', encoding='latin1')
```

۲. بررسی ساختار داده

- تعداد رکوردها: ۱,۰۰۰,۰۰۰
- تعداد ستون‌ها: ۶۱

- ستون‌های کلیدی cat2_slug: دسته‌بندی سطح ۲ cat3_slug: دسته‌بندی سطح ۳ City_slug: شهر

۳. تحلیل دسته‌بندی سطح ۲ (cat2_slug)

دسته‌بندی	تعداد آگهی	درصد
residential-sell	۵۵۸,۷۰۸	۵۵.۹٪
residential-rent	۲۷۶,۵۵۸	۲۷.۷٪
commercial-rent	۷۶,۵۶۶	۷.۷٪
commercial-sell	۳۸,۸۶۱	۳.۹٪
temporary-rent	۲۹,۹۰۳	۳.۰٪
real-estate-services	۱۹,۴۰۳	۱.۹٪

نکته مهم: بیش از ۵۵٪ از آگهی‌ها مربوط به فروش مسکونی هستند.

۴. تحلیل دسته‌بندی سطح ۳ (cat3_slug)

دسته‌بندی	تعداد آگهی	درصد
apartment-sell	۳۰۳,۳۸۵	۳۰.۳٪
apartment-rent	۲۱۱,۸۸۰	۲۱.۲٪
plot-old	۱۳۳,۵۷۰	۱۳.۴٪
house-villa-sell	۱۲۱,۷۵۳	۱۲.۲٪
house-villa-rent	۶۴,۶۷۸	۶.۵٪
shop-rent	۴۵,۹۹۳	۴.۶٪
سایر دسته‌ها	...	...

نکته مهم: آپارتمان‌ها (فروش و اجاره) بیش از ۵۰٪ از کل آگهی‌ها را تشکیل می‌دهند.

۵. تحلیل دسته‌بندی شهرها

دسته‌بندی شهر	تعداد آگهی	درصد
---------------	------------	------

شهر کوچک	۴۹۸,۴۷۸	۵۱.۷٪
کلان شهر	۴۶۴,۷۹۹	۴۸.۳٪

مصورسازی‌ها

نمودارهای تولید شده:

1. **cat2_bar_chart.png** - نمودار میله‌ای توزیع دسته‌بندی سطح ۲
2. **cat2_pie_chart.png** - نمودار دایره‌ای توزیع دسته‌بندی سطح ۲
3. **cat3_bar_chart.png** - نمودار میله‌ای توزیع دسته‌بندی سطح ۳ (۲۰ دسته برتر)
4. **cat3_pie_chart.png** - نمودار دایره‌ای توزیع دسته‌بندی سطح ۳
5. **city_category_distribution.png** - توزیع آگهی‌ها بر اساس دسته‌بندی شهر
6. **city_category_pie_chart.png** - نمودار دایره‌ای دسته‌بندی شهر

بخش دوم: پیش‌بینی قیمت با یادگیری ماشین

معرفی

در این بخش، با استفاده از ۷ الگوریتم مختلف یادگیری ماشین، قیمت املاک پیش‌بینی شده است. هدف اصلی، یافتن بهترین مدل برای پیش‌بینی قیمت با بالاترین دقت است.

مراحل انجام شده

۱. پیش‌پردازش داده‌ها (Preprocessing)

الف) ایجاد متغیر هدف

با توجه به اینکه قیمت‌ها به سه شکل مختلف ثبت شده‌اند:

- transformable_price - قیمت فروش
- transformed_rent - اجاره تبدیل‌شده
- transformed_credit - رهن تبدیل‌شده

یک ستون واحد به نام target_price ایجاد شد.

```
def create_target(row):
```

```
    if pd.notna(row['transformable_price']) and row['transformable_price'] > 0:
```

```
        return float(row['transformable_price'])
```

```
    elif pd.notna(row['transformed_rent']) and row['transformed_rent'] > 0:
```

```
        return float(row['transformed_rent'])
```

```
    elif pd.notna(row['transformed_credit']) and row['transformed_credit'] > 0:
```

```
        return float(row['transformed_credit'])
```

```
    return np.nan
```

ب) مهندسی ویژگی‌ها (Feature Engineering)

ویژگی‌های جدید ساخته شده:

نام ویژگی	توضیح	فرمول
building_to_land_ratio	نسبت زیربنا به زمین	$\text{building_size} / \text{land_size}$
building_age	سن بنا	$1400 - \text{construction_year}$
total_amenities	تعداد امکانات	جمع امکانات موجود
price_per_sqm	قیمت هر متر مربع	$\text{target_price} / \text{building_size}$
transaction_type	نوع معامله	sell/rent/mortgage

۲. ویژگی‌های نهایی برای مدل‌سازی

ویژگی‌های عددی (۱۱ ویژگی):

- land_size - مساحت زمین
- building_size - زیربنا
- floor - طبقه
- rooms_count - تعداد اتاق
- total_floors_count - تعداد کل طبقات
- unit_per_floor - واحد در هر طبقه
- construction_year - سال ساخت
- building_to_land_ratio - نسبت زیربنا به زمین
- building_age - سن بنا
- total_amenities - تعداد امکانات
- price_per_sqm - قیمت هر متر مربع

ویژگی‌های باینری (۴ ویژگی):

- has_balcony - دارای بالکن
- has_elevator - دارای آسانسور

- دارای انباری - has_warehouse
- دارای پارکینگ - has_parking

ویژگی‌های کدگذاری شده:

- transaction_type با One-hot encoding

۳. الگوریتم‌های استفاده شده

دسته	مدل	توضیح
مدل‌های خطی	Linear Regression	رگرسیون خطی ساده
	Ridge Regression	با L2 regularization
	Lasso Regression	با L1 regularization
مدل‌های Ensemble	Random Forest	۵۰ درخت، عمق ۱۰
	Gradient Boosting	نرخ یادگیری ۰.۱
	XGBoost	Extreme Gradient Boosting
	LightGBM	Light Gradient Boosting

۴. ارزیابی مدل‌ها

معیارهای ارزیابی:

- **R² Score:** ضریب تعیین (هرچه به ۱ نزدیک‌تر بهتر)
- **MAE:** خطای مطلق متوسط (هرچه کمتر بهتر)
- **MSE:** خطای میانگین مربعات (هرچه کمتر بهتر)

نتایج مدل‌ها

مدل	Validation R ²	Test R ²	Test MAE (تومان)
Random Forest	۰.۹۹۸۵	۰.۹۹۸۴	۳۶,۳۳۴,۳۳۳
Gradient Boosting	۰.۹۹۶۲	۰.۹۹۵۵	۶۱,۹۰۳,۳۴۳

LightGBM	۰.۹۹۵۶	۰.۹۹۵۰	۶۵,۳۵۹,۳۵۹
XGBoost	۰.۹۹۵۷	۰.۹۹۴۹	۶۶,۸۰۸,۶۶۳
Lasso Regression	۳.۷۵۶-	۴.۸۵۱-	۱,۲۶۱,۲۱۵,۹۵۷
Ridge Regression	۳.۸۴۰-	۴.۹۲۰-	۱,۲۶۴,۴۳۵,۶۴۲
Linear Regression	۳.۸۴۸-	۴.۹۲۹-	۱,۲۶۴,۷۹۴,۶۴۸

بهترین مدل Random Forest :

نتایج بهترین مدل:

- Validation R^2 : ۰.۹۹۸۵
- Test R^2 : ۰.۹۹۸۴
- Test MAE: ۳۶,۳۳۴,۳۳۳ تومان
- Test MSE: ۳,۳۷۸,۸۱۳,۲۱۷,۴۸۲,۷۲۹

تحلیل نتایج:

۱. مدل ۹۹.۸٪ از تغییرات قیمت را توضیح می‌دهد
۲. میانگین خطای پیش‌بینی حدود ۳۶ میلیون تومان است
۳. مدل‌های Ensemble عملکرد بسیار بهتری نسبت به مدل‌های خطی دارند

اهمیت ویژگی‌ها (بر اساس Random Forest)

اهمیت	ویژگی	رتبه
بسیار بالا	price_per_sqm	۱
بالا	building_size	۲
بالا	transaction_type	۳
متوسط	rooms_count	۴
متوسط	building_age	۵

بخش سوم: مسائل پیشرفته

معرفی

در این بخش، سه مسئله پیشرفته و کاربردی بر اساس داده‌های دیوار حل شده است.

مسئله ۱: سیستم توصیه‌گر قیمت‌گذاری (Price Recommender)

شرح مسئله

فروشنده‌گان املاک معمولاً نمی‌دانند ملک خود را با چه قیمتی آگهی کنند. این سیستم با تحلیل ویژگی‌های ملک، قیمت پیشنهادی و بازه قیمتی مناسب را ارائه می‌دهد.

پیاده‌سازی

ویژگی‌های استفاده شده:

- مشخصات فیزیکی: زیربنا، تعداد اتاق، طبقه، تعداد کل طبقات
- سن بنا: محاسبه شده از سال ساخت
- امکانات: آسانسور، پارکینگ، بالکن، انباری
- نسبت‌های مهندسی: نسبت زیربنا به زمین

مدل:

- الگوریتم Random Forest Regressor :
- تعداد درخت: ۱۰۰
- عمق درخت: ۱۰
- تبدیل لاگاریتمی هدف برای بهبود عملکرد

```
class PriceRecommender:
```



```

def __init__(self):
    self.model = RandomForestRegressor(
        n_estimators=100,
        max_depth=10,
        random_state=42
    )
    self.scaler = StandardScaler()

def suggest_price_range(self, features):
    base_price = self.predict_price(features)
    error_margin = base_price * 0.15
    return {
        'recommended_price': base_price[0],
        'min_price': base_price[0] - error_margin[0],
        'max_price': base_price[0] + error_margin[0]
    }

```

نتایج:

• R^2 Score: ۰.۹۸۹۶

• MAE: ۲۴۶,۱۷۷,۷۴۷ تومان

مسئله ۲: تحلیل روند قیمتی در طول زمان

شرح مسئله

تحلیل و پیش‌بینی روند تغییرات قیمت در شهرهای مختلف ایران.

پیاده‌سازی

مراحل:

۱. تبدیل ستون `created_at_month` به نوع `DateTime`

۲. گروه‌بندی داده‌ها بر اساس شهر و ماه

۳. محاسبه میانگین قیمت در هر گروه

۴. تحلیل روند با رگرسیون خطی

معیارهای تحلیل هر شهر:

- نرخ رشد: درصد تغییر قیمت از ابتدا تا انتها
- شیب روند: مقدار تغییر قیمت در هر ماه
- نوسان‌پذیری: نسبت انحراف معیار به میانگین قیمت

نتایج تحلیل شهرها:

شهر	نرخ رشد	شیب روند (میلیون/ماه)	میانگین قیمت (میلیون)	نوسان‌پذیری
مشهد	۴۰۰۳.۴٪	۱۴۷.۵۱	۳,۰۶۱	۰.۴۳
اصفهان	۶۲۶.۰٪	۱۹.۱۸	۳,۹۷۱	۰.۳۲
کرج	۲۳۰.۲٪	۱۸.۴۹-	۳,۵۹۱	۰.۳۵
تهران	۶.۳٪	۳۸.۴۲	۴,۳۲۲	۰.۲۶
شیراز	۳۸.۰٪-	۱۰۴.۹۸-	۴,۳۷۷	۰.۲۹

مسئله ۳: تشخیص آگهی‌های غیرواقعی/کلاهبرداری

شرح مسئله

سیستمی برای شناسایی آگهی‌های مشکوک و غیرواقعی با استفاده از تکنیک‌های تشخیص ناهنجاری.

پیاده‌سازی

ویژگی‌های استخراج شده:

- قیمت هر متر مربع - price_per_sqm
- تعداد امکانات - amenities_count
- طول توضیحات - desc_length
- تعداد اتاق - rooms_count

مدل:

- **Isolation Forest**: الگوریتم
- نرخ آلودگی: ۵٪
- تعداد درخت: ۱۰۰

```
class FraudDetector:
```

```
    def __init__(self):
```

```
        self.model = IsolationForest(
```

```
            contamination=0.05,
```

```
            random_state=42,
```

```
            n_estimators=100
```

```
        )
```

```
        self.scaler = StandardScaler()
```

نتایج:

- تعداد آگهی‌های تحلیل شده: ۵۵۷,۳۴۵

- آگهی‌های مشکوک شناسایی شده: ۲۷,۸۶۸
- درصد آگهی‌های مشکوک: ۵.۰۰٪

فایل‌های خروجی

نام فایل	توضیح
cat2_distribution.csv	توزیع دسته‌بندی سطح ۲
cat3_distribution.csv	توزیع دسته‌بندی سطح ۳
city_category_distribution.csv	توزیع دسته‌بندی شهرها
model_results_q2.csv	نتایج همه مدل‌ها
best_model_q2.pkl	بهترین مدل ذخیره شده
scaler_q2.pkl	اسکیلر ذخیره شده

نمودارهای تولید شده

1. cat2_bar_chart.png - نمودار میله‌ای سطح ۲
2. cat2_pie_chart.png - نمودار دایره‌ای سطح ۲
3. cat3_bar_chart.png - نمودار میله‌ای سطح ۳
4. cat3_pie_chart.png - نمودار دایره‌ای سطح ۳
5. city_category_distribution.png - توزیع دسته‌بندی شهر
6. city_category_pie_chart.png - نمودار دایره‌ای شهر
7. model_comparison_q2.png - مقایسه مدل‌ها
8. best_model_predictions_q2.png - پیش‌بینی بهترین مدل
9. price_trend_analysis_fixed.png - تحلیل روند قیمتی

جمع‌بندی نهایی

۱. تحلیل آماری: بیش از ۵۵٪ آگهی‌ها مربوط به فروش مسکونی و بیش از ۵۰٪ مربوط به آپارتمان‌ها هستند.
۲. پیش‌بینی قیمت: مدل Random Forest با $R^2=0.9984$ بهترین عملکرد را داشت و می‌تواند با دقت بالایی قیمت املاک را پیش‌بینی کند.
۳. سیستم توصیه‌گر قیمت: با دقت ۰.۹۸۹۶ می‌تواند قیمت پیشنهادی مناسبی ارائه دهد.
۴. تحلیل روند: شهر مشهد با نرخ رشد ۴۰۰۳٪ بیشترین رشد قیمت را داشته است.
۵. تشخیص کلاهبرداری: حدود ۵٪ از آگهی‌ها به عنوان مشکوک شناسایی شدند.

تاریخ: جولای ۲۰۲۶

نویسنده: الناز رادمند